

[Título del trabajo]

[Subtítulo opcional]

[Nombre Apellido1]* [Nombre Apellido2]** [Nombre Apellido3]***

Grado en Ingeniería en Inteligencia Artificial — Escuela Politécnica Superior, Universidad de Alicante
Aprendizaje Avanzado — Curso 2025/2026

Resumen

*Resumen del trabajo en 150–250 palabras. Debe incluir: (1) el problema abordado y su relevancia real, (2) el dataset utilizado, (3) las problemáticas identificadas y las técnicas aplicadas, (4) los resultados principales. **Escríbelo al final, una vez completado el trabajo.***

Palabras clave: aprendizaje automático, [problemática 1], [problemática 2], [dataset], [otra palabra clave].

Índice

1. Introducción	3
2. Trabajo Relacionado	3
2.1. [Trabajos sobre el problema abordado]	3
2.2. [Técnicas para la problemática 1]	4
2.3. [Técnicas para la problemática 2]	4
3. Descripción del Problema y los Datos	4
3.1. Definición formal de la tarea	4
3.2. Dataset	4
3.3. Análisis exploratorio (EDA)	4
3.4. Problemáticas identificadas	5
4. Metodología	5
4.1. Preprocesamiento	5
4.2. Modelo <i>baseline</i>	5
4.3. Tratamiento de la problemática 1: [nombre]	5
4.4. Tratamiento de la problemática 2: [nombre]	5
4.5. Protocolo de evaluación	5
5. Experimentos y Resultados	6
5.1. Configuración experimental	6
5.2. Resultados comparativos	6
5.3. Resultados específicos por problemática	6

* [email1@alu.ua.es]
** [email2@alu.ua.es]
*** [email3@alu.ua.es]

6. Discusión	6
6.1. Interpretación de los resultados	7
6.2. Limitaciones	7
6.3. Implicaciones éticas, legales y sociales	7
7. Conclusiones	7
A. Contribución individual	7
B. Enlace al repositorio	7
C. Uso de herramientas de IA generativa	8

1. Introducción

Orientación

La introducción debe responder a cuatro preguntas: (1) ¿Cuál es el problema y por qué es relevante? (2) ¿Qué implicaciones éticas, sociales o legales tiene? (3) ¿Qué se propone hacer este trabajo? (4) ¿Cómo se organiza el resto del documento? No es un resumen del trabajo, sino una motivación y contextualización.

En los últimos años, el uso de modelos de aprendizaje automático en contextos de alto impacto social ha crecido de forma significativa, especialmente en áreas relacionadas con la toma de decisiones públicas. Uno de los ámbitos más sensibles es el sistema judicial, donde algoritmos de predicción se utilizan o se proponen como herramientas de apoyo para estimar la probabilidad de reincidencia de individuos dentro del sistema penal. Estos sistemas pueden influir en decisiones críticas como la concesión de libertad condicional, la asignación de recursos penitenciarios o la participación en programas de rehabilitación.

Sin embargo, la aplicación de estos modelos en entornos judiciales plantea desafíos fundamentales tanto técnicos como éticos. En particular, los errores de predicción pueden tener consecuencias graves a nivel individual y social: un *falso positivo* puede contribuir a decisiones injustamente restrictivas, mientras que un *falso negativo* puede subestimar el riesgo real de reincidencia. Además, diversos estudios han evidenciado la presencia de sesgos en los datos utilizados para entrenar estos modelos, lo que puede derivar en resultados discriminatorios hacia ciertos grupos demográficos.

En este contexto, el dataset *COMPAS Recidivism* de ProPublica se ha convertido en un referente para el estudio de estas problemáticas, al poner en evidencia posibles desigualdades raciales en sistemas de predicción de riesgo. A partir de este caso, surge la necesidad de analizar no solo el rendimiento predictivo de los modelos, sino también su equidad (*fairness*) y su capacidad de explicación (*explainability*), aspectos clave para su posible aplicación en entornos reales.

El presente proyecto tiene como objetivo desarrollar un modelo de aprendizaje automático para la predicción de reincidencia, acompañado de un análisis crítico de sus implicaciones éticas. En particular, se abordarán dos problemáticas principales: la detección y evaluación de sesgos en las predicciones mediante métricas de equidad, y la interpretabilidad del modelo mediante técnicas de explicabilidad (*XAI*), como *SHAP* (*SHapley Additive exPlanations*). De este modo, se busca no solo optimizar el rendimiento del modelo, sino también evaluar su transparencia, justicia y viabilidad en contextos judiciales reales.

El resto del artículo se organiza como sigue. La Sección 2 revisa el trabajo relacionado. La Sección 3 describe el *dataset* y el análisis exploratorio. La Sección 4 detalla la metodología. La Sección 5 presenta los resultados experimentales. La Sección 6 discute las implicaciones. La Sección 7 concluye el trabajo.

2. Trabajo Relacionado

Orientación

No se trata de resumir trabajos uno a uno, sino de sintetizar la literatura de forma crítica: ¿qué se ha hecho antes?, ¿qué limitaciones tienen esos enfoques?, ¿cómo se sitúa este trabajo respecto al estado del arte? Organiza la sección por temática en lugar de por autor. Cita al menos 5–6 referencias de calidad [1].

2.1. [Trabajos sobre el problema abordado]

[Síntesis de trabajos previos sobre el mismo problema o *dataset* [1, 2].]

2.2. [Técnicas para la problemática 1]

[Resumen del estado del arte en la primera problemática identificada [3].]

2.3. [Técnicas para la problemática 2]

[Resumen del estado del arte en la segunda problemática identificada [4].]

3. Descripción del Problema y los Datos

3.1. Definición formal de la tarea

Orientación

Define formalmente la tarea de aprendizaje: tipo de tarea (clasificación, regresión...), espacio de entrada y salida, y función objetivo. Por ejemplo: dado un vector de features $\mathbf{x} \in \mathbb{R}^d$, aprender $f: \mathbb{R}^d \rightarrow \mathcal{Y}$ que minimiza $\mathcal{L}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim P}[\ell(f(\mathbf{x}), y)]$.

[Definición formal de la tarea aquí.]

3.2. Dataset

Orientación

Describe el dataset: origen, licencia, número de instancias, número de features, variable objetivo y distribución de clases. Incluye también las consideraciones éticas sobre su uso: ¿quiénes son los individuos representados?, ¿cómo se recogieron los datos?, ¿hay sesgos de selección conocidos?

La Tabla 1 resume las características principales del *dataset* utilizado.

Tabla 1: Características del *dataset*.

Característica	Valor
Fuente / enlace	[UCI / Kaggle / ...]
Número de instancias	
Número de <i>features</i>	
Variable objetivo	
Distribución de clases	[X % clase 0 / Y % clase 1]
Valores ausentes	[Sí / No — estrategia de imputación]
Licencia	

3.3. Análisis exploratorio (EDA)

Orientación

Incluye las visualizaciones más informativas: distribución de la variable objetivo, correlaciones relevantes, distribución de variables sensibles si las hay. El EDA debe estar orientado a identificar las problemáticas del trabajo, no ser un catálogo exhaustivo de gráficas.

[Análisis exploratorio aquí: 2–3 párrafos con las figuras más relevantes.]

[Insertar figura del EDA.]

Figura 1: [Descripción de la figura del EDA.]

3.4. Problemáticas identificadas

Orientación

Justifica aquí qué problemáticas son relevantes para este problema concreto. La argumentación debe basarse en: (1) el contexto de uso real del sistema (¿quién usa el modelo?, ¿sobre quién toma decisiones?), (2) las características del dataset (¿hay atributos sensibles?, ¿está desbalanceado?), y (3) las obligaciones legales aplicables (RGPD, AI Act).

A partir del análisis del *dataset* y del contexto de uso del sistema, se han identificado las siguientes problemáticas:

- [Problemática 1]: [Justificación.]
- [Problemática 2]: [Justificación.]

4. Metodología

Orientación

Esta sección debe ser suficientemente detallada para que el trabajo sea reproducible. Describe el pipeline completo, justifica cada decisión de diseño, e incluye la formulación matemática de las técnicas que lo requieran.

4.1. Preprocesamiento

[Cadena de preprocesamiento: imputación de valores ausentes, escalado, codificación de variables categóricas, división train/test y estratificación.]

4.2. Modelo *baseline*

Orientación

El baseline es el punto de referencia contra el que compararás las técnicas aplicadas. Elige un modelo estándar apropiado para la tarea y justifica su elección.

[Descripción del modelo *baseline* y justificación.]

4.3. Tratamiento de la problemática 1: [nombre]

Orientación

Describe la técnica aplicada. Incluye la formulación matemática cuando sea necesaria para entender el método. Justifica por qué esta técnica es adecuada para el problema y el dataset elegidos.

[Descripción, formulación y justificación.]

4.4. Tratamiento de la problemática 2: [nombre]

[Descripción, formulación y justificación.]

4.5. Protocolo de evaluación

Orientación

Describe cómo se evalúan los modelos: tipo de validación cruzada, métricas elegidas y justificación de su elección. Si el dataset está desbalanceado, justifica el uso de métricas

robustas (F1, AUC-ROC, etc.) en lugar de accuracy.

[Descripción del protocolo de evaluación y justificación de las métricas elegidas.]

5. Experimentos y Resultados

Orientación

Esta sección presenta los resultados sin interpretarlos (la interpretación va en la Sección 6). Usa tablas comparativas que permitan ver claramente la diferencia entre el baseline y cada intervención. Reporta siempre media $\pm$ desviación estándar cuando uses validación cruzada.

5.1. Configuración experimental

[Entorno de experimentación: versiones de librerías principales y semilla aleatoria fijada.]

Listing 1: Semilla aleatoria y versiones principales.

```
1 import numpy as np
2 SEED = 42
3 np.random.seed(SEED)
4 # sklearn.__version__ = X.X.X
```

5.2. Resultados comparativos

La Tabla 2 compara el rendimiento del *baseline* con los modelos que incorporan las técnicas para cada problemática.

Tabla 2: Comparativa de resultados (media $\pm$ desv. estándar, validación cruzada 5 *folds*).

Modelo / Configuración	AUC-ROC	F1	Métrica específica	Tiempo (s)
<i>Baseline</i>	0.XX $\pm$ 0.XX	0.XX $\pm$ 0.XX	—	
+ Problemática 1	0.XX $\pm$ 0.XX	0.XX $\pm$ 0.XX	0.XX	
+ Problemática 2	0.XX $\pm$ 0.XX	0.XX $\pm$ 0.XX	0.XX	

5.3. Resultados específicos por problemática

[Figuras o tablas específicas de cada problemática: *summary plot* de SHAP, curva privacidad-utilidad, comparativa de métricas de *fairness*, etc.]

[Insertar figura específica de la problemática 1.]

Figura 2: [Descripción del resultado de la problemática 1.]

[Insertar figura específica de la problemática 2.]

Figura 3: [Descripción del resultado de la problemática 2.]

6. Discusión

Orientación

Interpreta los resultados en el contexto del problema real: ¿qué significan para los usuarios afectados por el sistema? Analiza las limitaciones con rigor y evita afirmaciones genéricas

sobre ética; las implicaciones deben ser específicas y estar fundamentadas en los resultados obtenidos.

6.1. Interpretación de los resultados

[Interpreta los resultados en el contexto del problema real: 2–3 párrafos.]

6.2. Limitaciones

[Identifica y analiza las limitaciones no triviales: supuestos asumidos, restricciones del *dataset*, limitaciones de las técnicas aplicadas.]

6.3. Implicaciones éticas, legales y sociales

[Reflexión sobre las implicaciones reales del sistema. ¿Cómo afectan los resultados a los grupos implicados? ¿Qué obligaciones legales aplicarían bajo el RGPD o el AI Act?]

7. Conclusiones

Orientación

Síntesis de las contribuciones en 3–4 párrafos. Lecciones aprendidas. Líneas de trabajo futuro concretas y bien motivadas (no genéricas como “aplicar deep learning”).

[Conclusiones aquí: 3–4 párrafos.]

Referencias

- [1] A. Autor1 y B. Autor2, “Título del artículo,” *Nombre de la Revista*, vol. X, núm. Y, pp. ZZ–ZZ, año. DOI:XX.XXXX/XXXXXXXX
- [2] C. Autor3, “Título del artículo,” in *Proc. Nombre de la Conferencia (ABREV)*, Ciudad, País, año, pp. ZZ–ZZ.
- [3] D. Autor4, E. Autor5 y F. Autor6, “Título del artículo,” *arXiv preprint arXiv:XXXX.XXXXX*, año. arXiv:XXXX.XXXXX
- [4] G. Autor7, *Título del libro*, N. ed. Ciudad: Editorial, año.

A. Contribución individual

Tabla 3: Contribución de cada miembro del grupo.

Miembro	Contribución principal
[Nombre Apellido1]	[EDA, preprocesamiento, Sección 3]
[Nombre Apellido2]	[Implementación problemática 1, Sección 4.3]
[Nombre Apellido3]	[Implementación problemática 2, Sección 4.4]

B. Enlace al repositorio

El código fuente del trabajo está disponible en: [https://github.com/\[usuario\]/\[nombre-repositorio\]](https://github.com/[usuario]/[nombre-repositorio])

C. Uso de herramientas de IA generativa

Orientación

Indica si has utilizado herramientas de IA generativa (ChatGPT, GitHub Copilot, etc.) en la elaboración del trabajo, cómo las has usado y en qué partes. Si no se han utilizado, indícalo explícitamente.

[Descripción del uso, o bien: “No se han utilizado herramientas de IA generativa en la elaboración de este trabajo”.]