

[Título del trabajo]

[Subtítulo opcional]

[Nombre Apellido1]* [Nombre Apellido2]** [Nombre Apellido3]***

Grado en Ingeniería en Inteligencia Artificial — Escuela Politécnica Superior, Universidad de Alicante
Aprendizaje Avanzado — Curso 2025/2026

Resumen

*Resumen del trabajo en 150–250 palabras. Debe incluir: (1) el problema abordado y su relevancia real, (2) el dataset utilizado, (3) las problemáticas identificadas y las técnicas aplicadas, (4) los resultados principales. **Escríbelo al final, una vez completado el trabajo.***

Palabras clave: aprendizaje automático, [problemática 1], [problemática 2], [dataset], [otra palabra clave].

Índice

1. Introducción	3
2. Trabajo Relacionado	3
2.1. Modelos de predicción de reincidencia y el impacto de COMPAS	3
2.2. Equidad algorítmica y mitigación de sesgos	4
2.3. Explicabilidad (XAI) en el entorno judicial	4
3. Descripción del Problema y los Datos	5
3.1. Definición formal de la tarea	5
3.2. Dataset	5
3.3. Análisis exploratorio (EDA)	6
3.4. Problemáticas identificadas	6
4. Metodología	6
4.1. Preprocesamiento	7
4.2. Modelo <i>baseline</i>	7
4.3. Tratamiento de la problemática 1: [nombre]	7
4.4. Tratamiento de la problemática 2: [nombre]	7
4.5. Protocolo de evaluación	7
5. Experimentos y Resultados	7
5.1. Configuración experimental	7
5.2. Resultados comparativos	8
5.3. Resultados específicos por problemática	8

* [email1@alu.ua.es]

** [email2@alu.ua.es]

*** [email3@alu.ua.es]

6. Discusión	8
6.1. Interpretación de los resultados	8
6.2. Limitaciones	8
6.3. Implicaciones éticas, legales y sociales	8
7. Conclusiones	9
A. Contribución individual	10
B. Enlace al repositorio	10
C. Uso de herramientas de IA generativa	10

1. Introducción

Orientación

La introducción debe responder a cuatro preguntas: (1) ¿Cuál es el problema y por qué es relevante? (2) ¿Qué implicaciones éticas, sociales o legales tiene? (3) ¿Qué se propone hacer este trabajo? (4) ¿Cómo se organiza el resto del documento? No es un resumen del trabajo, sino una motivación y contextualización.

En los últimos años, el uso de modelos de aprendizaje automático en contextos de alto impacto social ha crecido de forma significativa, especialmente en áreas relacionadas con la toma de decisiones públicas. Uno de los ámbitos más sensibles es el sistema judicial, donde algoritmos de predicción se utilizan o se proponen como herramientas de apoyo para estimar la probabilidad de reincidencia de individuos dentro del sistema penal. Estos sistemas pueden influir en decisiones críticas como la concesión de libertad condicional, la asignación de recursos penitenciarios o la participación en programas de rehabilitación.

Sin embargo, la aplicación de estos modelos en entornos judiciales plantea desafíos fundamentales tanto técnicos como éticos. En particular, los errores de predicción pueden tener consecuencias graves a nivel individual y social: un *falso positivo* puede contribuir a decisiones injustamente restrictivas, mientras que un *falso negativo* puede subestimar el riesgo real de reincidencia. Además, diversos estudios han evidenciado la presencia de sesgos en los datos utilizados para entrenar estos modelos, lo que puede derivar en resultados discriminatorios hacia ciertos grupos demográficos.

En este contexto, el dataset *COMPAS Recidivism* de ProPublica se ha convertido en un referente para el estudio de estas problemáticas, al poner en evidencia posibles desigualdades raciales en sistemas de predicción de riesgo. A partir de este caso, surge la necesidad de analizar no solo el rendimiento predictivo de los modelos, sino también su equidad (*fairness*) y su capacidad de explicación (*explainability*), aspectos clave para su posible aplicación en entornos reales.

El presente proyecto tiene como objetivo desarrollar un modelo de aprendizaje automático para la predicción de reincidencia, acompañado de un análisis crítico de sus implicaciones éticas. En particular, se abordarán dos problemáticas principales: la detección y evaluación de sesgos en las predicciones mediante métricas de equidad, y la interpretabilidad del modelo mediante técnicas de explicabilidad (*XAI*), como *SHAP* (*SHapley Additive exPlanations*). De este modo, se busca no solo optimizar el rendimiento del modelo, sino también evaluar su transparencia, justicia y viabilidad en contextos judiciales reales.

El resto del artículo se organiza como sigue. La Sección 2 revisa el trabajo relacionado. La Sección 3 describe el *dataset* y el análisis exploratorio. La Sección 4 detalla la metodología. La Sección 5 presenta los resultados experimentales. La Sección 6 discute las implicaciones. La Sección 7 concluye el trabajo.

2. Trabajo Relacionado

2.1. Modelos de predicción de reincidencia y el impacto de COMPAS

La aplicación de algoritmos de aprendizaje automático (*Machine Learning*, ML) en el sistema de justicia penal se ha expandido como una herramienta para reducir los altos índices de reincidencia, que en diversas jurisdicciones internacionales alcanzan el 50 %. La literatura científica ha evolucionado desde el uso de escalas estadísticas simples hacia modelos complejos que buscan optimizar la toma de decisiones sobre libertad condicional y rehabilitación. En términos de rendimiento, revisiones sistemáticas recientes sitúan el estado del arte en una precisión (*ACC*) media de 0.81 y un área bajo la curva (*AUC*) de 0.74 [5].

Diversos estudios han explorado una amplia gama de arquitecturas para maximizar esta capacidad predictiva. Por ejemplo, Duwe y Kim (2017) emplearon algoritmos de *LogitBoost*

sobre el *dataset* MnSTARR+, obteniendo un *ACC* de 0.82 y un *AUC* de 0.78 [8]. Por su parte, Singh y Mohapatra (2021) propusieron un modelo de ensamble (*Ensemble Learning*) combinando clasificadores Bayesiano, KNN y SVM, alcanzando un *ACC* de 0.87 en poblaciones de delincuentes primerizos [11]. En contextos institucionales específicos, Butsara et al. (2019) reportaron precisiones de hasta 0.90 mediante regresión logística aplicada a internos en Tailandia [12]. Asimismo, para tipos de delitos específicos como el sexual, trabajos basados en Análisis Discriminante Lineal (LDA) y *Random Forest* han reportado valores de *ACC* de hasta 0.96 y *AUC* de 0.78, respectivamente [13, 14]. A pesar de estos avances técnicos, el caso de COMPAS ha puesto de manifiesto que un alto rendimiento no excluye la presencia de sesgos críticos, impulsando la necesidad de evaluar la equidad junto con la precisión [6, 7].

En este marco, el uso del *dataset* COMPAS personifica la tensión entre la eficacia técnica y la integridad ética, tras la investigación de ProPublica [6] que evidenció disparidades críticas a pesar de los rendimientos alcanzados. Si bien se han reportado precisiones elevadas con arquitecturas avanzadas, estudios comparativos indican que modelos interpretables como la regresión logística —frecuentemente utilizada en este dominio— presentan una validez predictiva y un rendimiento similares a algoritmos de “caja negra” como *Random Forest*. Esta falta de superioridad empírica de los modelos complejos, sumada a su diseño inaccesible para el usuario humano, subraya la necesidad de transitar hacia algoritmos transparentes o técnicas de *Explainable AI* (XAI) que permitan discernir cómo influyen individualmente variables como la etnia o la edad en la evaluación final del riesgo.

2.2. Equidad algorítmica y mitigación de sesgos

El principal desafío identificado en la literatura no reside únicamente en la capacidad predictiva, sino en la presencia de sesgos discriminatorios, particularmente raciales y de edad. Diversas investigaciones han señalado que estos sesgos pueden heredarse de métodos de recolección de datos sesgados o de un preprocesamiento inadecuado, factores que influyen significativamente en el rendimiento final del modelo.

El enfoque actual en el estado del arte, ejemplificado por trabajos como los de Karimi-Haghighi y Castillo [7], se centra en integrar métricas de equidad (*fairness*) directamente en el ciclo de vida del modelo. No obstante, una limitación crítica en muchos estudios previos es la falta de explicitud sobre el proceso de preprocesamiento, lo que dificulta la comparabilidad entre diferentes técnicas de mitigación de sesgo.

2.3. Explicabilidad (XAI) en el entorno judicial

La naturaleza de “caja negra” de muchos modelos avanzados de aprendizaje automático constituye una barrera crítica en el sistema judicial, ya que impide evaluar si la predicción de riesgo cumple con principios de justicia y debido proceso. Según la taxonomía establecida por Arrieta et al. [15], la explicabilidad no debe entenderse como un concepto unívoco, sino como una propiedad dependiente de la *audiencia* (jueces, abogados o acusados), quienes requieren distintos niveles de transparencia técnica y comprensibilidad para validar las decisiones del sistema.

En este ámbito, el estado del arte distingue entre modelos **intrínsecamente transparentes** —que cumplen con propiedades de simulatabilidad, decomposabilidad y transparencia algorítmica— y técnicas de **explicabilidad post-hoc** [15]. Estas últimas son esenciales cuando se emplean algoritmos de alta complejidad (como *XGBoost* o Redes Neuronales) para predecir la reincidencia, permitiendo iluminar el proceso de decisión sin sacrificar el rendimiento predictivo.

Dentro de los métodos *post-hoc*, la técnica *SHAP* (*SHapley Additive exPlanations*) se ha consolidado como el estándar para cuantificar la contribución de cada variable. No obstante, una limitación significativa de su implementación original (*Kernel SHAP*) es el supuesto de independencia entre las características. Como demuestran Aas et al. [16], en entornos judiciales

donde las variables socioeconómicas y delictivas suelen presentar una alta correlación, ignorar estas dependencias puede derivar en explicaciones inexactas o sesgadas.

Para abordar este desafío, la literatura reciente propone extensiones de *SHAP* que incorporan la dependencia de variables mediante el uso de **Cóputas Gaussianas** y **distribuciones condicionales empíricas** [16]. Estas técnicas permiten una descomposición del riesgo más fiel a la realidad delictiva, facilitando incluso la **agrupación (clustering)** de contribuciones de variables dependientes para ofrecer una visión más clara y accionable a los operadores jurídicos.

3. Descripción del Problema y los Datos

3.1. Definición formal de la tarea

Orientación

Define formalmente la tarea de aprendizaje: tipo de tarea (clasificación, regresión...), espacio de entrada y salida, y función objetivo. Por ejemplo: dado un vector de features $\mathbf{x} \in \mathbb{R}^d$, aprender $f: \mathbb{R}^d \rightarrow \mathcal{Y}$ que minimiza $\mathcal{L}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim P}[\ell(f(\mathbf{x}), y)]$.

El problema abordado en este trabajo se enmarca dentro del aprendizaje supervisado, concretamente como una tarea de **clasificación binaria**.

Sea un espacio de entrada $\mathcal{X} \subseteq \mathbb{R}^d$, donde cada vector de características $\mathbf{x} \in \mathcal{X}$ representa el perfil de un individuo procesado por el sistema judicial. Definimos el espacio de salida o variable objetivo como $\mathcal{Y} = \{0, 1\}$, donde $y = 1$ indica que el individuo reincide en un plazo de dos años (*two-year recidivism*) y $y = 0$ indica que no lo hace. Adicionalmente, denotamos por $A \in \mathcal{A}$ al atributo sensible o protegido presente en el espacio de entrada (en nuestro caso, la raza del individuo), donde $\mathcal{A}$ representa los posibles grupos demográficos (por ejemplo, afroamericano o caucásico).

El objetivo principal del sistema es aprender una función predictiva $f: \mathcal{X} \rightarrow [0, 1]$ que estime la probabilidad de reincidencia $\hat{y} = P(y = 1 | \mathbf{x})$, minimizando el riesgo esperado respecto a una función de pérdida ℓ :

$$\mathcal{L}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim P}[\ell(f(\mathbf{x}), y)]$$

Sin embargo, dado el alto impacto social de las decisiones judiciales, la optimización tradicional del modelo predictivo está sujeta a restricciones de **equidad algorítmica** (*fairness*). Por lo tanto, el objetivo de la tarea se reformula como un problema de optimización restringida, donde se busca minimizar la pérdida $\mathcal{L}(f)$ garantizando simultáneamente que el modelo cumpla con una métrica de equidad predefinida. Por ejemplo, si se busca optimizar bajo el criterio de Paridad Demográfica (*Demographic Parity*), la predicción del modelo debe ser estadísticamente independiente del atributo sensible:

$$P(\hat{y} = 1 | A = a) = P(\hat{y} = 1 | A = b) \quad \forall a, b \in \mathcal{A}$$

De este modo, la tarea no se limita a maximizar el rendimiento predictivo (precisión), sino a explorar empíricamente el compromiso (*trade-off*) entre la precisión y la equidad algorítmica, incorporando posteriormente técnicas de explicabilidad (XAI) para auditar las predicciones $\hat{y}$ a nivel global y local.

3.2. Dataset

Orientación

Describe el dataset: origen, licencia, número de instancias, número de features, variable objetivo y distribución de clases. Incluye también las consideraciones éticas sobre su uso:

¿quiénes son los individuos representados?, ¿cómo se recogieron los datos?, ¿hay sesgos de selección conocidos?

La Tabla 1 resume las características principales del *dataset* utilizado.

Tabla 1: Características del *dataset* COMPAS original.

Característica	Valor
Fuente / enlace	ProPublica (repositorio oficial en GitHub)
Número de instancias	7214 registros originales[cite: 1] (se reducen a 6167 tras la limpieza).
Número de <i>features</i>	53 variables originales[cite: 1] (se seleccionan 13 relevantes para el modelado).
Variable objetivo	two_year_recid [cite: 1] (Binaria: 1 = reincide, 0 = no reincide).
Distribución de clases	Aprox. 55 % clase 0 / 45 % clase 1 (en el subconjunto final filtrado).
Valores ausentes	Sí, el 18.6 % de las celdas totales están vacías[cite: 1]. Estrategia: Eliminación de columnas con alto porcentaje de nulos (ej. c_arrest_date con 84.2 % [cite: 1]) y filtrado de filas mediante eliminación por lista (<i>listwise deletion</i>).
Licencia	Open Data / Dominio público.

3.3. Análisis exploratorio (EDA)

Orientación

Incluye las visualizaciones más informativas: distribución de la variable objetivo, correlaciones relevantes, distribución de variables sensibles si las hay. El EDA debe estar orientado a identificar las problemáticas del trabajo, no ser un catálogo exhaustivo de gráficas.

[Análisis exploratorio aquí: 2–3 párrafos con las figuras más relevantes.]

[Insertar figura del EDA.]

Figura 1: [Descripción de la figura del EDA.]

3.4. Problemáticas identificadas

Orientación

Justifica aquí qué problemáticas son relevantes para este problema concreto. La argumentación debe basarse en: (1) el contexto de uso real del sistema (¿quién usa el modelo?, ¿sobre quién toma decisiones?), (2) las características del dataset (¿hay atributos sensibles?, ¿está desbalanceado?), y (3) las obligaciones legales aplicables (RGPD, AI Act).

A partir del análisis del *dataset* y del contexto de uso del sistema, se han identificado las siguientes problemáticas:

- **[Problemática 1]:** [Justificación.]
- **[Problemática 2]:** [Justificación.]

4. Metodología

Orientación

Esta sección debe ser suficientemente detallada para que el trabajo sea reproducible.

Describe el pipeline completo, justifica cada decisión de diseño, e incluye la formulación matemática de las técnicas que lo requieran.

4.1. Preprocesamiento

[Cadena de preprocesamiento: imputación de valores ausentes, escalado, codificación de variables categóricas, división train/test y estratificación.]

4.2. Modelo *baseline*

Orientación

El baseline es el punto de referencia contra el que compararás las técnicas aplicadas. Elige un modelo estándar apropiado para la tarea y justifica su elección.

[Descripción del modelo *baseline* y justificación.]

4.3. Tratamiento de la problemática 1: [nombre]

Orientación

Describe la técnica aplicada. Incluye la formulación matemática cuando sea necesaria para entender el método. Justifica por qué esta técnica es adecuada para el problema y el dataset elegidos.

[Descripción, formulación y justificación.]

4.4. Tratamiento de la problemática 2: [nombre]

[Descripción, formulación y justificación.]

4.5. Protocolo de evaluación

Orientación

Describe cómo se evalúan los modelos: tipo de validación cruzada, métricas elegidas y justificación de su elección. Si el dataset está desbalanceado, justifica el uso de métricas robustas (F1, AUC-ROC, etc.) en lugar de accuracy.

[Descripción del protocolo de evaluación y justificación de las métricas elegidas.]

5. Experimentos y Resultados

Orientación

Esta sección presenta los resultados sin interpretarlos (la interpretación va en la Sección 6). Usa tablas comparativas que permitan ver claramente la diferencia entre el baseline y cada intervención. Reporta siempre media $\pm$ desviación estándar cuando uses validación cruzada.

5.1. Configuración experimental

[Entorno de experimentación: versiones de librerías principales y semilla aleatoria fijada.]

Listing 1: Semilla aleatoria y versiones principales.

```
1 import numpy as np
2 SEED = 42
3 np.random.seed(SEED)
```

5.2. Resultados comparativos

La Tabla 2 compara el rendimiento del *baseline* con los modelos que incorporan las técnicas para cada problemática.

Tabla 2: Comparativa de resultados (media $\pm$ desv. estándar, validación cruzada 5 *folds*).

Modelo / Configuración	AUC-ROC	F1	Métrica específica	Tiempo (s)
<i>Baseline</i>	0.XX $\pm$ 0.XX	0.XX $\pm$ 0.XX	—	
+ Problemática 1	0.XX $\pm$ 0.XX	0.XX $\pm$ 0.XX	0.XX	
+ Problemática 2	0.XX $\pm$ 0.XX	0.XX $\pm$ 0.XX	0.XX	

5.3. Resultados específicos por problemática

[Figuras o tablas específicas de cada problemática: *summary plot* de SHAP, curva privacidad–utilidad, comparativa de métricas de *fairness*, etc.]

[Insertar figura específica de la problemática 1.]

Figura 2: [Descripción del resultado de la problemática 1.]

[Insertar figura específica de la problemática 2.]

Figura 3: [Descripción del resultado de la problemática 2.]

6. Discusión

Orientación

Interpreta los resultados en el contexto del problema real: ¿qué significan para los usuarios afectados por el sistema? Analiza las limitaciones con rigor y evita afirmaciones genéricas sobre ética; las implicaciones deben ser específicas y estar fundamentadas en los resultados obtenidos.

6.1. Interpretación de los resultados

[Interpreta los resultados en el contexto del problema real: 2–3 párrafos.]

6.2. Limitaciones

[Identifica y analiza las limitaciones no triviales: supuestos asumidos, restricciones del *dataset*, limitaciones de las técnicas aplicadas.]

6.3. Implicaciones éticas, legales y sociales

[Reflexión sobre las implicaciones reales del sistema. ¿Cómo afectan los resultados a los grupos implicados? ¿Qué obligaciones legales aplicarían bajo el RGPD o el AI Act?]

7. Conclusiones

Orientación

Síntesis de las contribuciones en 3–4 párrafos. Lecciones aprendidas. Líneas de trabajo futuro concretas y bien motivadas (no genéricas como “aplicar deep learning”).

[Conclusiones aquí: 3–4 párrafos.]

Referencias

- [1] A. Autor1 y B. Autor2, “Título del artículo,” *Nombre de la Revista*, vol. X, núm. Y, pp. ZZ–ZZ, año. DOI:XX.XXXX/XXXXXXXX
- [2] C. Autor3, “Título del artículo,” in *Proc. Nombre de la Conferencia (ABREV)*, Ciudad, País, año, pp. ZZ–ZZ.
- [3] D. Autor4, E. Autor5 y F. Autor6, “Título del artículo,” *arXiv preprint arXiv:XXXX.XXXXX*, año. arXiv:XXXX.XXXXX
- [4] G. Autor7, *Título del libro*, N. ed. Ciudad: Editorial, año.
- [5] G. V. Travaini, F. Pacchioni, S. Bellumore, M. Bosia y F. De Micco, “Machine Learning and Criminal Justice: A Systematic Review of Advanced Methodology for Recidivism Risk Prediction,” *International Journal of Environmental Research and Public Health*, vol. 19, núm. 17, p. 10594, 2022. DOI:10.3390/ijerph191710594
- [6] J. Angwin, J. Larson, S. Mattu y L. Kirchner, “Machine Bias,” *ProPublica*, 2016. URL: propublica.org/machine-bias
- [7] M. Karimi-Haghighi y C. Castillo, “Enhancing a recidivism prediction tool with machine learning: Effectiveness and algorithmic fairness,” in *Proc. 18th International Conference on Artificial Intelligence and Law (ICAIL)*, São Paulo, Brasil, 2021, pp. 79–88. DOI:10.1145/3462757.3466144
- [8] G. Duwe y K. Kim, “Out with the Old and in with the New? An Empirical Comparison of Supervised Learning Algorithms to Predict Recidivism,” *Criminal Justice Policy Review*, vol. 28, núm. 6, pp. 570–600, 2017. DOI:10.1177/0887403415604899
- [9] D. Gunning y D. W. Aha, “DARPA’s explainable artificial intelligence program,” *AI Magazine*, vol. 40, núm. 2, pp. 44–58, 2019. DOI:10.1609/aimag.v40i2.2850
- [10] A. Chouldechova, “Fair prediction with disparate impact: A study of bias in recidivism prediction instruments,” *Big Data*, vol. 5, núm. 2, pp. 153–163, 2017. DOI:10.1089/big.2016.0047
- [11] A. Singh y S. Mohapatra, “Development of risk assessment framework for first time offenders using ensemble learning,” *IEEE Access*, vol. 9, pp. 135024–135033, 2021.
- [12] N. Butsara, P. Athonthitichot y P. Jodpimai, “Predicting recidivism to drug distribution using machine learning techniques,” in *Proc. 17th Int. Conf. on ICT and Knowledge Engineering*, Bangkok, Tailandia, 2019, pp. 1–5.
- [13] N. Tollenaar y P. G. M. van der Heijden, “Which method predicts recidivism best?: A comparison of statistical, machine learning and data mining predictive models,” *J. R. Stat. Soc. Ser. A Stat. Soc.*, vol. 176, pp. 565–584, 2013.

- [14] B. Salo, T. Laaksonen y P. Santtila, “Predictive Power of Dynamic (vs. Static) Risk Factors in the Finnish Risk and Needs Assessment Form,” *Crim. Justice Behav.*, vol. 46, pp. 939–960, 2019.
- [15] A. B. Arrieta, N. Díaz-Rodríguez, J. Del Ser et al., “Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges,” *Information Fusion*, vol. 58, pp. 82–115, 2020. DOI:10.1016/j.inffus.2019.12.012
- [16] K. Aas, M. Jullum y A. Løland, “Explaining individual predictions when features are dependent: More accurate approximations to Shapley values,” *Artificial Intelligence*, vol. 298, p. 103502, 2021. DOI:10.1016/j.artint.2021.103502

A. Contribución individual

Tabla 3: Contribución de cada miembro del grupo.

Miembro	Contribución principal
[Nombre Apellido1]	[EDA, preprocesamiento, Sección 3]
[Nombre Apellido2]	[Implementación problemática 1, Sección 4.3]
[Nombre Apellido3]	[Implementación problemática 2, Sección 4.4]

B. Enlace al repositorio

El código fuente del trabajo está disponible en: [https://github.com/\[usuario\]/\[nombre-repositorio\]](https://github.com/[usuario]/[nombre-repositorio])

C. Uso de herramientas de IA generativa

Orientación

Indica si has utilizado herramientas de IA generativa (ChatGPT, GitHub Copilot, etc.) en la elaboración del trabajo, cómo las has usado y en qué partes. Si no se han utilizado, indícalo explícitamente.

[Descripción del uso, o bien: “No se han utilizado herramientas de IA generativa en la elaboración de este trabajo”.]